

SECCIÓN 5 — Telemetría Dinámica y "Concept Drift" en Hardware Cuántico

En el hardware cuántico, los parámetros físicos sufren una variabilidad temporal continua debido a fluctuaciones ambientales microscópicas, como cambios térmicos o interacciones con sistemas de dos niveles (TLS)¹. Los estudios empíricos en procesadores de IBM demuestran que las métricas de fidelidad de las compuertas lógicas, los tiempos de relajación T_1 y decoherencia T_2 , y las tasas de error de los resonadores de lectura sufren deriva estocástica (drift) en escalas de tiempo de horas a días [Poggi et al., 2024, arXiv:2405.04401]³. Los proveedores como IBM Quantum abordan este problema implementando rutinas automatizadas de calibración diaria (por ejemplo, a través de *Qiskit Runtime*) que monitorean de cerca y recalibran los pulsos de microondas cuando detectan un desvío [IBM Quantum, 2024, Qiskit Documentation]².

A nivel de Aprendizaje Automático (Machine Learning), el entrenamiento consciente del tiempo y la robustez ante la "deriva de concepto" (*Concept Drift*) son áreas de estudio críticas. En dominios de series temporales y fiabilidad de sistemas, se ha demostrado que las arquitecturas profundas a menudo experimentan distorsión de la salida cuando se exponen a distribuciones alteradas; por ende, evaluar los modelos en divisiones temporales estrictamente secuenciales (por ejemplo, entrenar con días anteriores y validar en días posteriores) es la única manera de garantizar la estabilidad operacional en el tiempo [Abedi et al., 2026, World Electr. Veh. J., doi:10.3390/wevj17030149]⁴. Específicamente para la mitigación cuántica (ML-QEM), los estudios señalan que los modelos entrenados estáticamente pueden fallar al intentar generalizar sobre datos de calibración desplazados o distribuciones "Out-Of-Distribution" (OOD), subrayando la importancia vital de usar divisiones temporales rigurosas durante el entrenamiento de redes GNN [Placidi et al., 2026, arXiv:2601.14226]⁵.

SECCIÓN 6 — Protocolos de Circuitos de Benchmarking para la Mitigación de Ruido

La validación cruzada y el benchmarking de los modelos de mitigación son esenciales, apoyándose la comunidad en protocolos bien definidos. Los circuitos aleatorios de Clifford son fundamentales debido a que son fácilmente simulables de forma clásica; IBM los emplea intensivamente en procedimientos como el Benchmarking Aleatorizado Entrelazado (Interleaved RB) y la métrica de *Layer Fidelity* (Fidelidad de Capa) para mapear eficientemente errores e identificar diafonía en el chip [Chen et al., 2023, arXiv:2510.01181]⁶. Asimismo, los circuitos espejo (*Mirror Circuits*) representan un método revolucionario de *full-stack benchmarking* en el que se ejecuta un circuito entrelazador seguido directamente por su inverso matemático, proporcionando una salida libre de errores determinista sin requerir los costos exponenciales del cálculo matricial clásico [Hines et al., 2023, arXiv:2312.14107]⁸.

Sin embargo, para propósitos de investigación en ML-QEM, los modelos puramente aleatorios no son suficientes. Los circuitos paramétricos y variacionales (tales como el Ansatz Eficiente en Hardware, HEA, y algoritmos estructurados como QAOA o QFT) son las configuraciones preferidas debido a que representan auténticas cargas de trabajo de la era NISQ y exhiben topologías de entrelazamiento denso que son vulnerables a la diafonía [Liao et al., 2024, Nature Machine Intelligence, doi:10.1038/s42256-024-00927-2]⁹. Estos se eligen por encima de algoritmos rígidos (como Grover) ya que generan una gran variedad de distribuciones dinámicas en lugar de un único pico de probabilidad, evitando que la red neuronal aprenda atajos triviales o funciones delta. El consenso actual en la literatura de mitigación dicta el uso de conjuntos de entrenamiento mixtos donde la mayoría está compuesta por circuitos aleatorios —obligando a la IA a aprender física de ruido estocástico puro— y se valida contra circuitos estructurados y anchos para comprobar su universalidad algorítmica [Bao et al., 2025, ICLR, arXiv:2406.11633]¹⁰.

SECCIÓN 7 — Brecha de Investigación y Posicionamiento de esta Tesis

A través de la revisión del estado del arte, se evidencia un rápido aumento de investigaciones en ML-QEM; el uso de GNNs sobre Grafos Acíclicos Dirigidos (DAG) [Tudisco et al., 2025, arXiv:2507.19093]¹¹ incorporando metadatos físicos extraídos de la telemetría [Wang et al., 2022, ICCAD, doi:10.1145/3508352.3561118]¹² ha mostrado resultados competentes al superar los límites de las interpolaciones puramente analíticas. A nivel matemático, los enfoques clásicos sin matrices, ejemplificados por M3, logran escalar resolviendo iterativamente el subespacio de resultados medidos, limitando la complejidad espacial a $\mathcal{O}(N)$ [Nation et al., 2021, PRX Quantum, doi:10.1103/PRXQuantum.2.040326]¹³.

⚠ Brecha Crítica (Research Gap): A pesar de los desarrollos mencionados, **no existe literatura previa publicada** que combine simultáneamente en un único pipeline *MLOps end-to-end*: (a) codificación cuántica DAG-to-graph; (b) características de nodo embebidas desde la calibración telemetría diaria; (c) un régimen de entrenamiento **estrictamente desacoplado** de mitigación de errores de compuerta (GEM, continuo) frente a lectura (REM, discreto marginal); y (d) un motor iterativo de inversión de subespacios *Matrix-Free* acoplado dinámicamente con las predicciones locales de las redes GNN operando bajo un protocolo severo de *Concept Drift* temporal OOD.

El trabajo más próximo a la propuesta de esta tesis es el reciente *GTraQEM* [Bao et al., 2025, ICLR, arXiv:2406.11633]¹⁰, el cual utiliza un Graph Transformer sin paso de mensajes local para la mitigación del ruido basándose en telemetría topológica de los circuitos. Esta tesis va más allá y se distingue de *GTraQEM* al:

1. **Desacoplar las Fases:** Aislar analíticamente el ruido unitario de compuertas frente al colapso de medición; permitiendo a un Transformer corregir desvíos de escalares Δ por separado de una GNN que rectifica histogramas.
2. **Solucionador de Subespacio M3:** Integrar el solver iterativo de Krylov clásico (GMRES)

como el motor de inferencia matemática para las GNN marginales del REM, previniendo los colapsos de Memoria RAM exponencial $\mathcal{O}(2^{3n})$.

3. **Adaptación MLOps a la Deriva Física:** Aplicar una validación cruzada temporal *Out-Of-Distribution* (OOD) entre varios días discretos de telemetría simulada (gemelo digital), garantizando con rigor de ingeniería que el pipeline sobrevive al inevitable *Concept Drift* del hardware NISQ moderno.

Obras citadas

1. What is a Quantum Calibration? - QuEra, <https://www.quera.com/glossary/quantum-calibration>
2. Monitoring, calibrations, and benchmarking | IBM Quantum Documentation, <https://quantum.cloud.ibm.com/docs/guides/calibration-jobs>
3. Cross-platform hardware benchmark of style-based quantum GANs for data augmentation on superconducting and trapped-ion processors - arXiv, <https://arxiv.org/html/2405.04401>
4. Safe-Calibrated TCN-Transformer Transfer Learning for Reliable Battery SoH Estimation Under Lab-to-Field Domain Shift - ResearchGate, https://www.researchgate.net/publication/402510685_Safe-Calibrated_TCN-Transformer_Transfer_Learning_for_Reliable_Battery_SoH_Estimation_Under_Lab-to-Field_Domain_Shift
5. Deep Learning Approaches to Quantum Error Mitigation - arXiv, <https://arxiv.org/pdf/2601.14226>
6. Combining Error Detection and Mitigation: A Hybrid Protocol for Near-Term Quantum Simulation - arXiv, <https://arxiv.org/html/2510.01181v1>
7. Parameter Analysis and Optimization of Layer Fidelity for Quantum Processor Benchmarking at Scale - arXiv, <https://arxiv.org/html/2510.16915v1>
8. Scalable Full-Stack Benchmarks for Quantum Computers - arXiv, <https://arxiv.org/html/2312.14107v1>
9. Machine Learning for Practical Quantum Error Mitigation - OpenReview, <https://openreview.net/pdf?id=xYbECDx0JF>
10. BEYOND CIRCUIT CONNECTIONS: ANON-MESSAGE PASSING GRAPH TRANSFORMER APPROACH TOWARDS QUANTUM ERROR MITIGATION - ICLR Proceedings, https://proceedings.iclr.cc/paper_files/paper/2025/file/c276c3303c0723c83a43b95a44a1fcbf-Paper-Conference.pdf
11. Graph Neural Network-Based Predictor for Optimal Quantum Hardware Selection - arXiv, <https://arxiv.org/html/2507.19093v1>
12. QuEst: Graph Transformer for Quantum Circuit Reliability Estimation - arXiv, <https://arxiv.org/html/2210.16724v2>
13. Scalable Mitigation of Measurement Errors on Quantum Computers - ResearchGate, https://www.researchgate.net/publication/356056096_Scalable_Mitigation_of_Measurement_Errors_on_Quantum_Computers